VISUALISASI DATA DAN INFORMASI / INFORMATIKA

Palmer Observatory

Multi-DBMS Data Pipeline dan Visualisasi Interaktif
Data Penguin Antarktika

Nama	Mohamad Rizal Rahmadi
NIM	230660121114
Dosen	Irfan Fadil
Tanggal penyusunan	31 Oktober 2026

Ringkasan proyek

Palmer Observatory mengintegrasikan data pengukuran individu dari SQLite dan metadata penelitian dari DuckDB. Kedua hasil kueri digabungkan di tingkat aplikasi menggunakan Pandas, kemudian ditampilkan melalui Streamlit dan Plotly. Dataset memuat 344 observasi tiga spesies penguin di Kepulauan Palmer pada 2007-2009.

Tujuan analisis

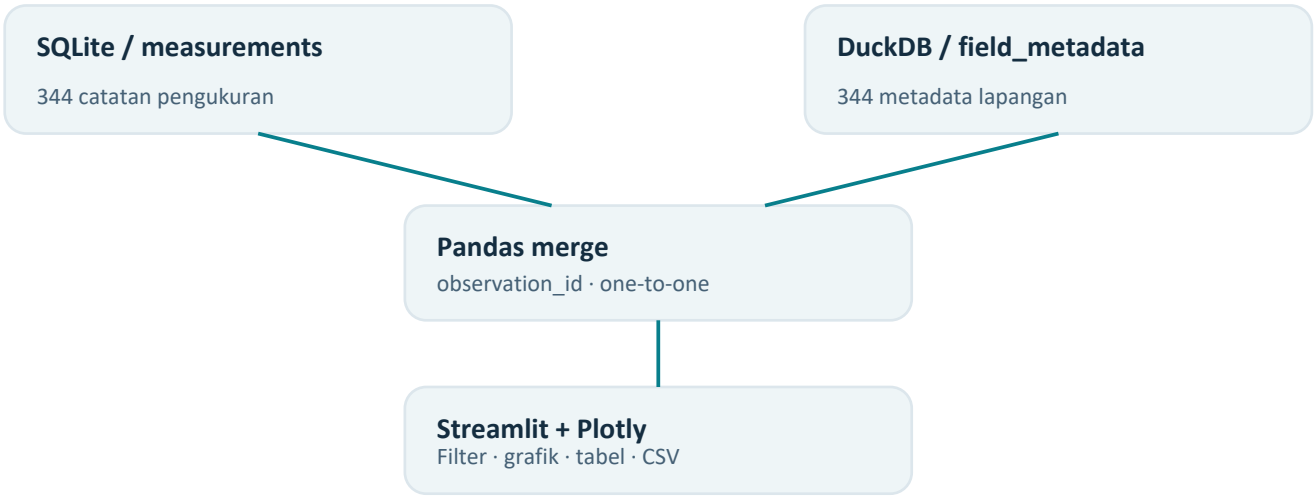
Mengeksplorasi perbedaan massa tubuh antarspesies, hubungan panjang sirip dengan massa tubuh, serta komposisi pengambilan sampel menurut pulau dan tahun. Visualisasi dilengkapi filter, tooltip, zoom, tabel, unduhan CSV, dan audit nilai kosong.

Skenario penggunaan

Tim pemantauan ekologi memisahkan pengukuran operasional dari arsip metadata lapangan. Arsitektur ini memperjelas tanggung jawab penyimpanan dan menunjukkan integrasi dua engine. Pada dataset kecil ini, pemisahan dilakukan untuk demonstrasi pembelajaran, bukan karena kebutuhan performa.

Implementasi: Python 3.12 · SQLite · DuckDB · SQLAlchemy · Pandas · Streamlit · Plotly

Arsitektur dan integrasi data



Peran masing-masing DBMS

Komponen	Fungsi dan isi
SQLite	Tabel measurements: spesies, pulau, tahun, jenis kelamin, panjang/kedalaman paruh, panjang sirip, massa tubuh.
DuckDB	Tabel field_metadata: studi, sampel, nama ilmiah, identitas lapangan, tahap reproduksi, tanggal telur, isotop, dan komentar.

Alur yang dapat direplikasi

1. Baca dua CSV sumber yang disertakan; verifikasi SHA-256 terhadap manifest.

2. Periksa 344 pasangan baris dan keselarasan ukuran, spesies, pulau, tahun, serta jenis kelamin. Nomor urut sumber yang tervalidasi menjadi observation_id.

3. Bangun skema dan seed kedua DBMS. Primary key mencegah ID ganda; constraint membatasi domain data pengukuran.

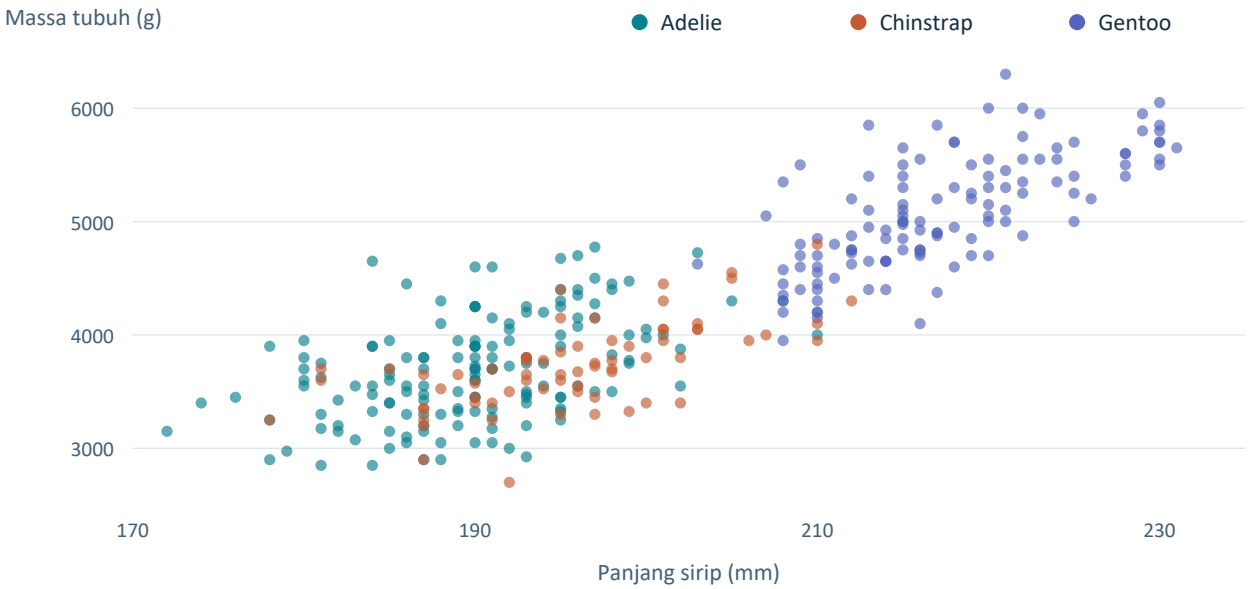
4. Jalankan SELECT SQLite dengan SQLAlchemy dan SELECT DuckDB dengan konektor Python resmi. Gabungkan DataFrame dengan left merge dan validate="one_to_one".

5. Pastikan seluruh observasi memiliki metadata, jumlah baris tidak berubah, dan pulau antarsumber cocok. Hasil join baru diteruskan ke filter dan visualisasi.

Keamanan dan deployment

Engine embedded tidak memerlukan password database. Tidak ada kredensial remote yang ditulis dalam kode. Database hasil seed tidak masuk Git dan dapat dibangun ulang saat penyimpanan hosting terhapus. Konfigurasi lokasi penyimpanan menggunakan PALMER_DATA_DIR bila diperlukan.

Hasil eksplorasi dan kualitas data



Gambar 1. Hubungan panjang sirip dan massa tubuh, 342 pasangan ukuran tersedia. Sumber: Palmer Penguins; visualisasi diolah dari snapshot yang sama dengan aplikasi.

Spesies	n observasi	n massa	Rerata massa (g)
Adelie	152	151	3.700,66
Chinstrap	68	68	3.733,09
Gentoo	124	123	5.076,02

Temuan utama

Gentoo memiliki rerata massa tubuh tertinggi pada sampel ini. Titik Gentoo cenderung berada pada panjang sirip dan massa yang lebih besar. Rerata massa seluruh data adalah 4.201,75 g dari 342 pengukuran; jumlah observasi keseluruhan tetap 344.

Penanganan nilai kosong

Masing-masing empat variabel morfologi kosong pada dua observasi. Keempat ukuran lengkap pada 342 observasi (99,4%). Jenis kelamin tidak tercatat pada 11 observasi dan diberi label unknown. Tidak ada imputasi. Rerata dan grafik menggunakan nilai yang tersedia sesuai variabelnya; filter morfologi lengkap tidak mensyaratkan jenis kelamin terisi.

Batas interpretasi

Data merupakan sampel historis penguin dewasa pada tahap satu telur, dari Biscoe, Dream, dan Torgersen. Jumlah sampel tahunan bukan estimasi populasi. Pola hubungan bersifat deskriptif; perbedaan spesies, lokasi, dan jenis kelamin dapat memengaruhi hasil. Analisis tidak membuktikan sebab-akibat atau kondisi terkini.

Verifikasi dan tautan pengumpulan

Pengujian	Hasil
Sumber, jumlah baris, dan hasil join	Lulus: 344 pasangan, ID unik, nilai pengukuran terjaga.
Dua engine dan seed ulang	Lulus: SQLite dan DuckDB berisi 344 baris; seed ulang tidak menggandakan data.
Filter dan missing values	Lulus: kombinasi filter, data kosong, dan nilai hilang sesuai sumber.
Validasi metadata rusak	Lulus: pasangan hilang atau pulau salah ditolak.
Streamlit AppTest	Lulus: lima grafik, ekspor CSV, filter Gentoo 124/123, dan kondisi kosong.

Hasil pengujian otomatis: 5 passed. Pengujian memverifikasi alur aplikasi dan integrasi; keterjangkauan aplikasi publik dicatat terpisah di bawah.

Tautan utama

Aplikasi live: https://palmer-observatory.streamlit.app/

Repositori: github.com/Jayouss/palmer-observatory

Data dan sumber penelitian

Horst, A. M., Hill, A. P., & Gorman, K. B. (2020). palmerpenguins: Palmer Archipelago (Antarctica) penguin data. Data Dr. Kristen Gorman dan Palmer Station LTER; lisensi CC0.

allisonhorst.github.io/palmerpenguins/
Dataset asli: github.com/allisonhorst/palmerpenguins/tree/main/inst/extdata

Gorman, K. B., Williams, T. D., & Fraser, W. R. (2014). Ecological Sexual Dimorphism and Environmental Variability within a Community of Antarctic Penguins (Genus Pygoscelis). PLOS ONE, 9(3), e90081. doi:10.1371/journal.pone.0090081

Referensi teknik dan kode

Streamlit - layout, widget, dan pengujian: github.com/streamlit/streamlit

Plotly - scatter, bar, box plot, dan tooltip: github.com/plotly/plotly.py

DuckDB - koneksi dan kueri analitik: github.com/duckdb/duckdb

SQLAlchemy - koneksi engine SQLite: github.com/sqlalchemy/sqlalchemy

Pandas - merge dan agregasi: github.com/pandas-dev/pandas

Implementasi disusun khusus untuk tugas ini dengan bantuan AI; referensi digunakan untuk mempelajari API dan teknik. Skema, skrip seed, kode, dependensi, dan dokumentasi tersedia dalam repositori.